

基于用户偏好的信任网络随机游走推荐模型

张萌*, 南志红

(山西财经大学, 信息管理学院, 山西 太原 030006)

(*通信作者电子邮箱 1216081662@qq.com)

摘要: 为了提高推荐算法评分预测的准确度, 解决冷启动用户推荐问题, 在 TrustWalker 模型基础上提出一种基于用户偏好的随机游走模型 PtTrustWalker。首先, 利用矩阵分解法对社会网络中的用户、项目相似度进行计算; 其次, 将项目进行聚类, 通过用户评分计算用户对项目类的偏好和不同项目类下的用户相似度; 最后, 利用权威度和用户偏好将信任细化为不同类别下用户的信任, 并在游走过程中利用信任用户最高偏好类中与目标物品相似的项目评分进行评分预测。该模型降低了噪声数据的影响, 从而提高推荐结果的稳定性。实验结果表明, PtTrustWalker 模型在推荐质量和推荐速度方面相比于现有随机游走模型有所提高。

关键词: 基于信任网络推荐; 用户偏好; 随机游走; 推荐系统; 冷启动

中图分类号: TP391(信息处理)

文献标志码: A

Trust network random walk model based on the user preferences

ZHANG Meng, NAN Zhihong

(Faculty of Information and Management, Shanxi University of Finance and Economics, Shanxi Taiyuan 030006, China)

Abstract: In order to improve the accuracy of the rating prediction and resolve the cold-start problems in recommended systems, the random walk model based on user preferences, named PtTrustWalker, was proposed, which based on the Trust Walker model. First, the similarity of users and items was calculated in social networks through matrix factorization method. And then, the items were clustered and the user's preference to items and the similarity of user's in different categories were calculated through user's scores. Finally, by making use of authority score and user preference, the credibility was detailed into user's credit in different categories in order to forecast score in the process of migration. The proposed model decreases the influence of noisy data and improves the stability of the recommendation. The experiments show that, the PtTrustWalker model makes some improvements in the quality and speed of recommendation comparing with the existing random walk models.

Keywords: Trust-based network recommendation; user preference; random walk; recommendation system; cold start

0 引言

随着互联网的快速发展, 移动设备、Web 服务所产生的大量数据使用户难以从中选择满足其需求的服务。为帮助用户在信息过载的情况下能够获取所需信息, 推荐系统应运而生并在电子商务领域发挥重要作用, 如 Amazon、豆瓣、Facebook 等网站中推荐服务已经成为其个性化服务的重要组成部分。为精确有效为用户进行推荐, 研究者提出了多种推荐算法并不断改进, 其中协同过滤^[1]是目前应用最为广泛的推荐算法之一。

而面对推荐系统中普遍出现的冷启动问题, 协同过滤由于其推荐机制局限性, 无法对存在冷启动问题的系统进行推荐。现有的解决方式大多是将流行物品推荐给用户, 或利用用户上下文信息进行推荐来缓解冷启动问题。而随着在线社交网络的兴起, 引入信任网络已经成为改进协同过滤的一个重要手段。在信任网络中, 目标用户信任的邻居用户可以被推荐相同的服务。Golbeck^[2]提出的 TidalTrust 模型在信任网络中使用改进的广度优先搜索策略, 从离目标用户最短路径中找出所有对预测项目评分的用户, 以此来预测用户对该项目的评分。Massa 等^[3]提出的 MoleTrust 模型利用信任传播理论评估信任值的方式, 提高了利用信任网络推荐准确性和覆

收稿日期: 2016-06-15; 修回日期: 2016-09-06。基金项目:

作者简介: 张萌(1990-), 男, 山西太原人, 硕士研究生, 主要研究方向: 智能系统、金融预测、推荐系统; 南志红(1964-), 女, 山西沁源人, 副教授, 硕士, 主要研究方向: 信息系统研发、商务智能。

盖率。Jamali 等^[4]将协同过滤与基于信任的推荐相结合,提出一种在信任网络中随机游走的模型 TrustWalker,有效地避免噪声数据的影响,游走过程中不仅考虑目标项目,同时考虑了信任用户在目标项目相似项目上的评分。其理论框架以信任网络为基础,协同过滤作为补充。朱丽中等^[5]提出的 CoTrustWalker 模型针对 TrustWalker 模型的不稳定性,采用云模型计算相似度,在小规模数据集上提高了推荐结果的稳定性,并保证了其推荐精确度。Deng^[6]等的 RelevantTrustWalker 模型将评分矩阵分解后利用特征矩阵进行相似度计算,同时利用用户相似度修正 TrustWalker 模型,提高了模型推荐质量。上述方法的局限之一在于信任用户的建议并不绝对适用于目标用户,因为两者可能有不同的偏好方向。

因此,针对上述模型中推荐适用性、模型稳定性等问题,本文提出了一种社会网络中基于用户偏好的 PtTrustWalker 模型。PtTrustWalker 在 TrustWalker 模型基础上通过细化信任、引入权威度等手段加强信任网络,使推荐更有针对性以及易解释性。并对原模型游走过程进行修正,加强模型的稳定性,一定程度上加快了推荐速度。最后在 Epinions 数据集上评估方法的准确性和效率,通过实验结果证明了所提算法可获得较好的推荐效果。

1 问题定义

文中 $U = \{u_1, u_2, \dots, u_n\}$ 表示用户集合, $S = \{s_1, s_2, \dots, s_m\}$ 用来表示项目集合。 $R = [r_{i,j}]_{n \times m}$ 为评分矩阵, $r_{i,j}$ 一般属于[1,5]之间的整数。 $T = [t_{u,v}]_{n \times n}$ 为信任矩阵, $t_{u,v} \in [0,1]$ 表示用户 u 和 v 之间的信任度,其中 0 表示不信任, 1 表示信任。推荐系统任务的定义如下:

定义 1 给定一个目标用户 $u_0 \in U$, 对其未评分项目 $s_0 \in S$ 进行预测评分, 即预测 r_{u_0, s_0} 的数值。

1.1 相似度计算

矩阵分解(Matrix Factorization, MF)^[7]以其高扩展性以及良好的预测能力备受研究者喜爱。MF 将评分矩阵分解成为两个低维矩阵——用户和项目潜在特征矩阵, 在保留主要信息特征的同时, 降低了数据维度, 为计算用户项目相似度提供便利。文中将用户评分矩阵 R 大致分解为两个矩阵 P 和 Q :

$$R \approx PQ^T \quad (1)$$

其中 $P \in R^{m \times d}$ 、 $Q \in R^{n \times d}$ 分别表示用户和项目的潜在特征矩阵, 两矩阵的每一行代表一个用户或物品的潜在特征

向量。分解后的矩阵, 利用余弦相似度来衡量用户之间和物品之间的相似性, 计算方式如下:

$$User_Sim(u, v) = \cos(u, v) = \frac{u \cdot v}{|u| \cdot |v|} \quad (2)$$

$$Item_Sim(s_i, s_j) = \cos(s_i, s_j) = \frac{s_i \cdot s_j}{|s_i| \cdot |s_j|} \quad (3)$$

下面的例子将清楚地说明计算过程。

例 1. 给定一个 6 名用户和 4 个物品的评分矩阵如下:

$$R = \begin{bmatrix} 5 & 3 & 0 & 2 \\ 5 & 0 & 2 & 2 \\ 3 & 4 & 0 & 3 \\ 0 & 0 & 5 & 1 \\ 3 & 5 & 1 & 1 \\ 5 & 3 & 2 & 5 \end{bmatrix}$$

将其分解后, 得到特征矩阵 P 和 Q :

$$P = \begin{bmatrix} -0.4427 & 0.2295 \\ -0.3626 & -0.3357 \\ -0.4106 & 0.2727 \\ -0.1146 & -0.8192 \\ -0.3940 & 0.2486 \\ -0.5793 & -0.1656 \end{bmatrix}$$

$$Q = \begin{bmatrix} -0.6980 & 0.0371 \\ -0.4993 & 0.4568 \\ -0.2131 & -0.8772 \\ -0.4670 & -0.1434 \end{bmatrix}$$

选择用户 u_4 (0.1146, -0.8192) 和 u_6 (-0.5793, -0.1656) 通过公式(2)可以计算相似度为 0.1390, 同理可由矩阵 Q 计算物品 s_1 与 s_3 相似度为 0.1842。可以在评分矩阵观察到两用户评分差异十分明显, 因此两者相似度不高。该方法可以较精确地计算用户和物品间相似度。

1.2 用户偏好

根据项目相似度, 将物品集合进行聚类 $S_C = \{S_{c1}, S_{c2}, \dots, S_{cn}\}$, 其中 n 为聚类数, 并可得到不同类别评分矩阵 $R = \{R_{c1}, R_{c2}, \dots, R_{cn}\}$ 。 R_{cn} 中评分不仅表示用户对项目喜好程度, 同时隐含了用户对项目所属类别 S_{cn} 的偏好度。例如, 用户对一部武侠电影评了高分, 能够推测用户对武侠类电影有较高的兴趣度, 在为该用户进行电影推荐时, 武侠片的效果相较于其他类型电影效果可能更好。本文就用户对项目类偏好度计算基于以下假设: 在某物品类中, 用户评分的项目数占用户总共评分的项目数的比例越高并且对该类中项目的平均评分越高, 则表示用户越有可能喜欢该类项目^[8]。只有同时符合两项条件时, 推测的可信度才越大。如用户在项目类 A 中评分次数占其总评分数比例很高, 但评

分都在 1~2 分(评分在 1~5 之间), 那么该用户对 A 类项目的偏好度可能不高, 若为其推荐类 A 中的项目, 效果可能不是很好。又如用户对项目 B 中某一物品评 5 分, 即该用户对 B 类项目平均评分为最高分, 但由于其评分次数过少, 不能因此确定用户偏向于 B 类项目。所以在同时满足两个条件时, 用户喜欢该项目类的可信度才越高。

$$P_{uc} = X_{uc} * Y_{uc} = \frac{|S_c \cap S_u|}{|S_u|} * \frac{\sum_{s \in S_c \cap S_u} r_{u,s}}{|S_c \cap S_u|} \quad (4)$$

$$= \frac{\sum_{s \in S_c \cap S_u} r_{u,s}}{|S_u|}$$

偏好由两部分组成: 类偏好数占总偏好比例 X , 类内平均喜好度 Y 。其中: S_c 表示项目类 c 中的物品集合; S_u 表示用户 u 评过分的物品集合; $r_{u,s}$ 表示用户 u 对项目 s 的评分。

1.3 信任度量

在推荐系统中, 信任常被认为与用户交互历史和评分喜好相关。其最大作用是帮助去除来自恶意虚假用户的信息, 保证信息真实性。现给出如下定义:

定义 2 信任是用户在其交互历史基础上所建立的相互依赖的关系, 是判断用户提供某种服务的能力的度量。

定义 3 信任度是信任等级的体现, 是反应用户信任关系的度量。信任具有不对称性、传递性、动态性等特性^[9]。

定义 4 信任度可分为局部信任和全局信任。局部信任度指用户对其他用户主观信任度。全局信任指的是社区中某个用户的总信任或权威度, 全局信任越大表明该用户在网络中影响力越大, 越容易得到其他用户的信赖。

本节首先介绍全局信任度, 即权威度的度量方法, 进而与类信任度融合得到细化后的信任网络。

1.4 权威度度量

Goldbaum^[10]在 2011 年提出 follow the leader 模型, 模型以两种用户类型 leader, follower 来区分用户, 其中 follower 在某个领域中较信任 leader, 即 leader 在一定程度上能够影响 follower 的决策。在社交平台中, 被许多人信任的用户具有较高的权威度, 可以引领其他用户作出决策, 如论坛中的资深版主, 微博的“大 V”都可以从某种程度上反映该用户的影响力。综上所述, 专家会被许多人信任, 并且评价能力能够代表物品的平均水平, 下面将阐述权威度的计算方法。

信任网络的传递性使得越被权威用户所信任的用户专家度越高, 将其定义为全局权威度。用户全局权威度由信任该用户的数量与质量度量, 可表示为:

$$PR(u) = \frac{(1-\alpha)}{|U|} + \alpha \sum_{u_i: (u_i, u) \in T} \frac{PR(u_i)}{Out(u_i)} \quad (5)$$

其中: $PR(u)$ 表示用户 u 的全局权威度; $|U|$ 为数据集中用户数量; $u_i: (u_i, u) \in T$ 表示信任 u 的用户; $Out(u_i)$ 表示用户 u_i 信任用户数; $\sum_{u_i: (u_i, u) \in T} \frac{PR(u_i)}{Out(u_i)}$ 表示信任用户 u 的用户传递给 u 的信任度。该公式结合社会网络信任特性, 较好地解释了用户全局权威度取决于信任该用户的所有用户的全局权威度。

社会网络中专家的评分往往与大众评分较为符合, 用户评价的物品数量与评价质量决定用户局部权威度, 其计算方式如下:

$$Au(u) = \frac{\sum_{s \in S_u} (1 - |r_{u,s} - \bar{r}_s| * e^{-|U(s)|})}{|N_{u_max}|} \quad (6)$$

其中 $\sum_{s \in S_u} (1 - |r_{u,s} - \bar{r}_s| * e^{-|U(s)|})$ 表示用户评价质量,

$|r_{u,s} - \bar{r}_s|$ 表示用户 u 对项目 s 评分与项目 s 平均得分偏离程度, 计算项目均分时应取出该用户对其评分已保证其公平性。计算中将评分归一化到 [0,1], 所以 $|r_{u,s} - \bar{r}_s| \in [0,1]$ 。

$e^{-|U(s)|}$ 反应了项目 s 流行程度, $|U(s)|$ 表示对项目 s 有评分的用户数, 评分用户越多 $e^{-|U(s)|}$ 越小;

$\sum_{s \in S_u} (1 - |r_{u,s} - \bar{r}_s| * e^{-|U(s)|})$ 越大表示用户 u 受信任程度越高。

同时, 用户权威度与自身评分数目有关, $|N_{u_max}|$ 表示评分次数最多的用户评分次数。

由上述结论可知用户权威度应由全局权威度与局部权威度衡量, 故将用户权威度 $Auth(u)$ 定义为:

$$Auth(u) = \alpha PR(u) + \beta Au(u) \quad (7)$$

其中参数 α, β 分别调节全局权威度和局部权威度占用户专家度的比例, $\alpha, \beta \in [0,1]$, $\alpha + \beta = 1$ 。 $Auth(u) \in (0,1)$ 值越大, 说明该用户在某些领域受信任越高, 越具有权威性。根据不同信任网络, 调节参数使用户权威度能有效影响其他用户评分的状态。

如前文所述, 局部信任关系直接应用于推荐系统并不总能增加预测精度, 依靠信任用户的推荐只能算是可靠, 但这样的建议并不绝对影响目标用户的评分, 因为目标用户和信任用户会有不同的兴趣偏好。因此对信任的细化工作是有必要的。本文将信任度分为全局信任和局部信任, 其中全局信任即上文所提权威度或专家度, 并将信任度与用户偏好相似性结合, 我们将其称为信任融合过程。本文认为用户相似度

越高其信任邻居的推荐越可靠, 否则会参考用户的声望影响力, 即用户权威度。用户 u 、 v 在 c 类的信任融合公式如下:

$$tr(u, v, c) = User_Sim(u, v, c) * t_{u,v} + (1 - User_Sim(u, v, c)) * Auth(v) \quad (8)$$

其中: $User_Sim(u, v, c)$ 表示在类别 c 下利用类评分矩阵 R_c 计算出的用户 u 与用户 v 相似度; $t_{u,v}$ 表示用户非对称的局部信任; $Auth(v)$ 表示用户 v 在信任网络的影响力。利用类相似度与权威度等信任度量, 可以有效区分不同信任用户推荐对目标用户的影响力。

2 PtTrustWalker 模型

在 TrustWalker 模型中仅对于目标用户和特定项目进行预测, 如前文 1.4 节所述, 仅依靠信任用户的推荐, 结果只是可靠。但这样的推荐在目标用户与信任用户的偏好有较大差异时, 解释性与预测效果并不理想。并且模型在游走过程中选择项目的随机性导致其推荐精度不高, 引入权威度并结合用户相似度细化信任同时修正其游走过程, 可以有效解决上述问题。本文借鉴 TrustWalker 模型框架, 结合偏好信任提出了一种基于用户偏好的信任网络随机游走 PtTrustWalker 模型, 模型框架如图 1, 并有如下改进:

- 1) TrustWalker 模型在局部信任网络中游走, 预测分数时没有考虑用户的偏好, 信任用户的推荐只能算是可靠, 但这样的建议并不绝对影响目标用户的评分。PtTrustWalker 模型将目标用户信任细化结合用户权威度, 针对不同类别项目预测时在类别信任网络中游走, 优先考虑同一类别的项目评分作为参考, 若停止用户在该类别未评分, 将根据停止用户具有高偏好的类别中与预测项目相似度最高的项目作为预测评分参考, 使得推荐具有较好的可解释性。
- 2) TrustWalker 模型以等概率选择下一跳转节点, 过高的随机性使其推荐精度不佳, 易限于盲目游走。考虑到信任网络特性, 用户相似度, 用户局部信任和权威度, 都应当作为选择节点时需要考虑的因素。这就是说当前用户更信任、更相似的节点在游走时以更大概率被选择, 作为评分参考。
- 3) 每趟游走停留节点的概率不仅应当考虑当前节点用户偏好相似度和游走的深度, 同时考虑到信任网络的传递性, 节点之间的信任度也需考虑。
- 4) 在随机游走过程中停留概率较小的及节点可能是噪声数据, 本文设定了全局游走停止条件。PtTrustWalker 模型在多趟游走得到一个用户参考列表, 当游走过程中

参考列表足够稳定并且符合预测需要时终止游走。

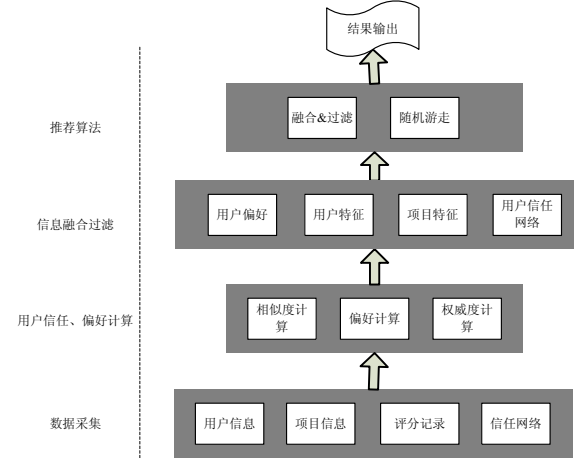


图 1 PtTrustWalker 模型框架

2.1 推荐算法

PtTrustWalker 模型通过多次迭代得到推荐结果。每一趟游走从目标用户 u_0 开始, 在其加权信任网络中游走。在第 k 步游走至特定用户 u , 若用户 u 对目标物品 s_0 有评分, 游走停止并返回当前节点及其评分作为游走结果。否则, 有如下几种情况:

- a) 随机游走以 $\phi_{u,k,sim,Tr}$ 的概率停留在当前用户 u 。若 u 在项目 s_0 所在类 c 有评分, 在 u c 类已评分项目中以 $F_u(c, s_i)$ 概率选择项目 s_i 的评分; 若 u 未在该类评分, 将在 u 偏好最高类中以 $F_u(c_{maxu}, s_j)$ 概率选择项目 s_j 的评分。其计算方式如下:

$$F_u(c, s_i) = \frac{Item_Sim(s_0, s_i)}{\sum_{s_j \in S_{cu}} Item_Sim(s_0, s_j)} \quad (9)$$

$F_u(c, s_i)$ 是通过轮盘赌博^[1]选择相似项目, 即相似度较高的项目更可能被选中。

停止的概率 $\phi_{u,k,sim,Tr}$ 受当前节点 u 与目标用户 u_0 相似度, 目标物品 s_0 与用户 u 评分过的物品相似度影响。另外, 当前用户与上一节点用户 u' 信任度也将作为重要参考因素, 用户信任度越高, 该用户的评分越有参考价值, 停止的概率越大。同时, 随着在信任网络游走深度的增加, 引入噪声的概率也越大, 随机游走停止的概率 $\phi_{u,k,sim,Tr}$ 也应该越大。因此, 综合以上考虑, 将 $\phi_{u,k,sim,Tr}$ 定义为:

$$\phi_{u',k,sim,Tr} = tr_{u_0,u',c} \times \frac{\max_{s_j \in S_{u'}} \{item_sim(s_0, s_j)\}}{1 + e^{-\frac{k}{2}}} \times Sim(u_0, u') \quad (10)$$

其中: $tr_{u,v,c}$ 为式(5)中用户融合信任度的计算方法;
 $Sim(u_0, u)$ 为计算用户相似度的方法; $itemsim(s_0, s_j)$ 表示物品相似度, k 表示当前游走的深度。

根据“六度分割理论”^[12,13], 本文将游走步数上限设为 6 步。更符合现实社会网络。随着游走深度的增加, 噪声数据的概率也不断增大, 因此限制游走步数有助于提高推荐效果。

b) 相反的, 将有 $1 - \phi_{u,k,sim,Tr}$ 的概率继续游走, 从当前用户

户 u 的融合信任邻居中选择下一步的游走目标

TrustWalker 从当前节点直接信任用户中随机选择作为下一步游走节点, 这意味着用户 u 的信任用户被选择的概率是相同的。这些用户对评分预测有不同的参考价值。为了区分不同用户对推荐的权重, 定义选择下一步节点 v 的概率计算方法:

$$P(v) = \frac{tr_{u,v,c}}{\sum_{\omega \in Tr_u} tr_{u,\omega,c}} \quad (11)$$

从节点 u 选择下一节点时, 须从用户 u 信任邻居中选取。 $tr_{u,v,c}$ 为式(5)中计算用户 u, v 信任度的方法。从式(11)可以看出, 用户 u 的信任邻居 v 作为下一游走节点的概率为两者信任度占用户 u 所有信任邻居信任度之和的比值, 融合信任度包含了用户相似度以及权威信任, 使得选择节点更加合理, 准确。

2.2 评分预测

PtTrustWalker 模型通过多次游走得到稳定的预测结果。最终的预测结果是通过聚合每次游走结果计算的值。其计算方法如下:

$$r_{u_0,s} = \frac{1}{n} \sum_{i=1}^n r_i \quad (12)$$

其中: r_i 为每趟随机游走结果; n 为游走次数。模型预测结果是多次随机游走执行结果的平均值。

PtTrustWalker 模型为获得稳定的预测结果, 需要进行一定次数的随机游走, 最终可以通过计算预测值方差 σ^2 来说明预测结果已经稳定且符合评分预测需要。其计算公式如下:

$$\sigma_i^2 = \frac{1}{i} \sum_{j=1}^i (r_j - \bar{r})^2 \quad (13)$$

其中: r_j 为此次随机游走的结果; i 为当前游走的次数。

σ_i^2 表示在执行 i 次随机游走后预测结果的方差。由式(13)可知, σ^2 最终趋近于一个固定的值, 表示预测结果已经稳

定。文中设定当 $|\sigma_{i+1}^2 - \sigma_i^2| \leq \varepsilon$ 时游走停止, 结束预测。实验中设定 $\varepsilon = 0.0001$ 。

3 实验及结果

3.1 实验设计

本文使用数据集为 Epinions 数据集^[3], 数据来自真实世界 Epinions 网站, 数据量非常巨大且具有冷启动和稀疏性问题, 数据集的具体信息如表 1 所示。

表 1 数据集信息

评分信息				信任信息	
用户数	物品数	评分数	稀疏度%	信任数	稀疏度%
49290	139738	664824	0.0097	487181	0.007

该数据集有 49290 个用户, 系统中有 139738 个不同的项目被评分过, 总评分次数为 664824 次, 其用用户评分矩阵密度不足 0.01%。每个用户平均有 13.4 条评分记录。信任数据集中, 总信任关系数为 487181 条, 每个用户平均有 9.9 个直接信任邻居。可以看到相比于常用的 MoiveLens 数据集 4.25% 的数据密度, Epinions 更加稀疏。因此, 该数据集能在大数据量与高稀疏性下评估模型的推荐效果。将评分少于 5 条的用户看作冷启动用户^[3]。在全集用户集和冷启动用户集分别进行实验。本文使用的留一法(Leave-one-out)是评分预测中广泛使用评估模型的方法, 保留一条评分信息, 将其余信息预测该评分。将 PtTrustWalker 分别在冷启动用户集和全体用户集下与以下五种方法进行比较: TidalTrust, MoleTrust, TrustWalker, CoTrustWalker 和 RelevantTrustWalker 模型。

实验使用 Intel Core i5 2.5Ghz 机器, 内存 12G, 操作系统为 Win 10 系统, 算法使用 Python 2.7 实现。比较算法的参数设定沿用原文中的参数值, 并对物品评分数小于 5 的用户看作冷启动用户, PtTrustWalker 模型中每趟游走最大深度为 6, 每趟游走次数为 10000 次。

3.2 实验评估方法

评分预测的预测准确度通常通过均方根误差(Root Mean Square Error, RMSE)计算, 该方法被许多研究所采用。RMSE 在测试集 N 中计算公式为:

$$RMSE = \sqrt{\frac{\sum_{u_0, i_0} (r_{u_0, i_0} - \hat{r}_{u_0, i_0})^2}{|N|}} \quad (14)$$

其中, r_{u_0, i_0} 和 \hat{r}_{u_0, i_0} 表示目标用户 u_0 对项目 i_0 的评分与预测评分。RMSE 值越小说明预测结果越准确。在高稀疏性的测试集中, 一些模型可能无法预测所有评分, 因此利用覆

盖率(Coverage)来评估模型来评估模型能够进行预测的用户项目对的比例。

$$coverage = \frac{S}{N} \tag{15}$$

其中：S 表示模型成功预测的次数；N 表示测试集项目评分次数。

利用 F-Measure 将 RMSE 和 coverage 结合成一个单一的评价指标，需将精度误差 RMSE 转化到[0,1]区间，精确度 (precision)和 F-Measure 的计算公式如下：

$$precision = 1 - \frac{RMSE}{4} \tag{16}$$

$$F - Measure = \frac{2 \times precision \times coverage}{precision + coverage} \tag{17}$$

3.3 实验结果

图 2 展示了将项目分为不同类别数时，PtTrustWalker 的 RMSE。从图 2 可知，项目分为 8 类时，在实验数据上可取得较好的结果。因此，在下文计算中，将项目分类数取 8。




图 2 项目分类数对推荐影响

图 3 将展示式(7)用户专家度参数对实验结果的影响，采用 RMSE 度量结果的准确性。如图 3 所示，在测试集中当 $\alpha = 0.6$ 、 $\beta = 0.4$ 时可以达到最好效果。相比于用户评分矩阵，用户信任矩阵相对稠密，提升全局权威度权重可以提高推荐准确度。在下文对比实验中，取 $\alpha = 0.6$ 、 $\beta = 0.4$ 时的实验结果与其他模型进行比较。




图 3 参数 α 与 β 对各数据集的影响

PtTrustWalker 等信任增强模型主要是为解决冷启动用户而提出的。因此，本文首先对模型在冷启动用户集上的评价表现进行评估。表 2 和图 4 给出了冷启动用户的比较结果。

表 2 冷启动用户集实验结果

模型	RMSE	Coverage/%	F-Measure
TidalTrust	1.368	59.95	0.6274
MoleTrust	1.437	57.49	0.6060
TrustWalker	1.262	72.39	0.7036
CoTrustWalker	1.254	72.85	0.7069
RelevantTrustWalker	1.173	79.55	0.7485
PtTrustWalker	1.147	79.90	0.7587




图 4 冷启动用户集实验结果(横坐标为对比模型)

从表 2 和图 4 的实验结果中，观察到 PtTrustWalker 在冷启动用户集中相比其他算法有着较高的精确度。由于引入了用户之间的信任关系，TidalTrust 和 MoleTrust 可以利用信任关系对冷启动用户进行推荐，但未提高推荐精度。TrustWalker、CoTrustWalker、RelevantTrustWalker 模型引入随机游走策略，相比 TidalTrust 和 MoleTrust 模型在推荐精度和覆盖率有着明显的提高。相比这三种随机游走方法，PtTrustWalker 选择将信任细化，并引入权威度，在游走过程中，选择更信任且在预测项目类别中偏好相似的用户，而不是随机选择。此外 CoTrustWalker, PtTrustWalker 覆盖率也是最高的，模型利用矩阵分解方法来计算相似度，避免了在稀疏评分矩阵中无法计算相似度的难题。因此，本文提出的 PtTrustWalker 模型在冷启动用户集上推荐效果优于其他算法。

表 3 全集用户集实验结果

模型	RMSE	Coverage/%	F-Measure
TidalTrust	1.197	81.15	0.7521
MoleTrust	1.201	83.47	0.7613
TrustWalker	1.129	92.10	0.8068
CoTrustWalker	1.085	94.23	0.8212
RelevantTrustWalker	1.042	98.16	0.8435
PtTrustWalker	1.017	98.17	0.8476

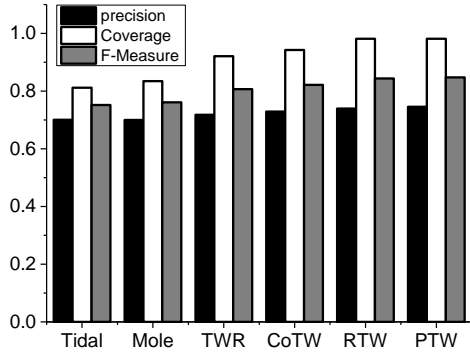


图 5 全集用户集实验结果 (横坐标为对比模型)

表 3 和图 5 显示了在全集用户集上几种模型的实验结果对比。相对于冷启动用户实验结果, 由于全集用户集的评分信息更为充足, 所有算法的效果相对于冷启动用户集推荐效果有着明显提高。从表 3 可以看出, 信任增强的推荐算法(包括 TidalTrust, MoleTrust, TrustWalker)由于在推荐过程中只考虑用户之间的信任, 没有考虑用户相似度对推荐的影响, 这导致模型推荐精度较低, 其覆盖率也不尽人意。后续的改进模型 CoTrustWalker 和 RelevantTrustWalker, 在此基础上结合用户信任度和相似度, 提高了推荐准确度。改进模型局限之一在于信任用户的建议并不绝对适用于目标用户, 针对该问题本文提出的 PtTrustWalker 模型引入了权威度, 并将用户信任度与相似度细化为不同项目类别下的信任与相似度, 改善模型在冷启动情况下的推荐效果的同时提高了模型推荐精度与解释性。因此, 本文提出的 PtTrustWalker 模型在全集用户集下推荐效果优于其他算法。

推荐系统的时间成本也是一个重要的评价指标。图 6 显示几个信任推荐模型的平均时间成本。相比于 TrustWalker 和 CoTrustWalker 随机游走模型, RelevantTrustWalker 与 PtTrustWalker 大大降低了推荐耗时。这是因为 RelevantTrustWalker 与 PtTrustWalker 在选择游走节点时不是随机地选择目标, 而是根据信任度计算下一步节点。这就使得推荐结果更快速地趋向于平稳, 提高了模型的计算效率。而相比于 RelevantTrustWalker, PtTrustWalker 将参考评分项目规定到停止用户中具有最高偏好的项目类中, 因此在项目相似度计算过程中, 只需计算某一类下的项目相似度, 节省了一定的推荐时间。

随机游走中每次游走的深度为社会网络直径 D , 在 PtTrustWalker 模型中, 引入“六度分割理论”将 D 最大值限定为 6, 更符合社会网络特点并降低噪声数据对推荐的影响。在 PtTrustWalker 模型每趟游走中, 需对用户与邻居的融合信任度以及特定项目类中项目的相似度进行计算。为计算用户信任度需对用户评分和信任邻居进行计算。同理, 需要利用用户对项目的评分来计算项目的相似度。总体而言, 一次随机游走的时间复杂度如下:

$$D \times \left(\frac{|E_c|}{|U_c|} \frac{|R_c|}{|U_c|} + \frac{|R_c|}{|U_c|} \frac{|R_c|}{|S_c|} \right) \quad (18)$$

其中 $\frac{|E_c|}{|U_c|}$ 为用户在项目类 c 的平均信任邻居数; $\frac{|R_c|}{|U_c|}$ 为用户

对项目类 c 中项目的平均评分次数; $\frac{|R_c|}{|S_c|}$ 为项目类 c 平均被评分

次数。评分预测的复杂度是 T 倍的单次游走复杂度, 其中 T 是 PtTrustWalker 模型预测结果稳定时游走次数。

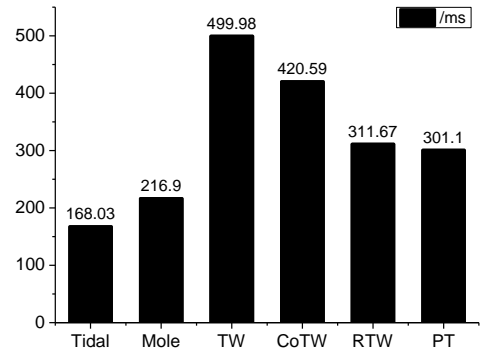


图 6 模型推荐时间对比结果

4 结语

在解决大型数据集个性化推荐问题上, 本文有三个出发点: 1) 解决冷启动用户推荐问题; 2) 解决高维稀疏评分矩阵推荐问题; 3) 是解决如何有效信任为用户推荐的问题。为解决问题 1), 本文在 TrustWalker 模型上提出了一种基于用户偏好的信任推荐方法, TrustWalker 本身就是为解决冷启动用户推荐所提出的算法。本文在此基础上, 在游走过程中选择偏好更相似, 信任度更高的目标节点, 使得每一次选择走向更相似的用户。实验证明这一改进是有效的, 并提高了模型的易解释性。对于问题 2), 利用矩阵分解, 在高维稀疏评分矩阵下可以高效精确的计算相似度。而对于问题 3), 由于信任用户与目标用户的偏好差异会使推荐精度降低, 本文将项目聚类并得到用户偏好, 在此基础上利用权威度和局部信任度等手段将信任度细化, 在游走中利用类信任度, 预测中参考停留用户高偏好类中相似度较高物品进行预测, 提高了算法的解释性和推荐精度。通过实验表明, 该方法能在现有的社会网络中直接应用, 具有较好的准确度和实时性。本文在计算用户信任时, 仅考虑了用户兴趣度这一上下文信息, 而上下文环境包括时间、位置、情绪等内容。文中未考虑时间因素对用户信任关系的影响, 用户之间的信任关系会随着时间的推移发生变化。同理, 用户对项目的评分也是对时间因素敏感的, 过时的评分信息会成为干扰推荐的噪音。因此, 利用

多维度上下文信息来增强推荐质量和用户满意度将是我们下一步的工作。

参考文献

- [1] Goldberg D, Nichols D, Oki BM, et al. Using collaborative filtering to weave an information tapestry [J]. Communications of the ACM, 1992,35(12):61-70.
- [2] Golbeck JA. Computing and applying trust in web-based social networks[C]// University of Maryland at College Park, 2005:199.
- [3] Massa P, Avesani P. Trust-aware recommender systems[C]// Proceedings of the 2007 ACM conference on Recommender systems. New York: ACM, 2007:17-24.
- [4] Jamali M, Ester M. Trustwalker: A random walk model for combining trust-based and item-based recommendation [C]//Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining. New York: ACM, 2009:397-406.
- [5] 朱丽中, 徐秀娟, 刘宇. 基于项目和信任的协同过滤推荐算法 [J]. 计算机工程, 2013, 39(1):58-62. (ZHU Li-zhong, XU Xiu-juan, LIU Yu. Collaborative Filtering Recommendation Algorithm Based on Item and Trust[J]. Computer Engineering, 2013, 39(1):58-62.)
- [6] Deng S, Huang L, Xu G. Social network-based service recommendation with trust enhancement [J]. Expert Systems with Applications, 2014, 41(18):8075-8084.
- [7] Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems [J]. Computer, 2009, 8):30-37.
- [8] 张碧云. 基于二分图的聚类推荐算法研究[D]. 华南理工大学, 2014:27-30 (Zhang Biyun .Recommendation Algorithm Research Based on Clustering in Bipartite Graph[D]. South China University of Technology, 2014:27-30)
- [9] Guo G, Zhang J, Thalmann D, et al. From ratings to trust: An empirical study of implicit trust in recommender systems[C]// ACM Symposium on Applied Computing, 2014:248-253.
- [10] Goldbaum D. Follow the leader: Simulations on a dynamic social network [J]. Available at SSRN 2358566, 2013:15-48
- [11] Lipowski A, Lipowska D. Roulette-wheel selection via stochastic acceptance [J]. Physica A: Statistical Mechanics and its Applications, 2012,391(6):2193-2196.
- [12] Watts DJ. Six degrees: The science of a connected age [J]. Reflections, 2003,:61(1):93.
- [13] Jamali S. Probabilistic models for recommendation in social networks[D]. Applied Sciences: School of Computing Science, 2013:61-63
- Zhang Meng,born in 1990,M.S.candidate.His research interests include intelligent system, financial prediction,recommendation system
- Nan Zhihong,born in 1964,M.S.,Associate professor.Her research interests include information system development,business intelligence.